

# 基於信念規則的多因子 深度學習模型 以預測股票價格

A Belief Rule-Based Multi-Factor  
Deep Learning Model  
for Stock Price Prediction

指導教授：翁頌舜 博士  
報告研究生：林寧

# 摘要

本研究提出一種 基於信念規則 (Belief Rule-Based, BRB) 的多因子深度學習模型BRBMDL，用於預測股票價格。

- 模型結合信念規則推理和深度學習技術
- 整合多種影響股價的因子（歷史股價、技術指標和情緒極性）

| 旨在克服普遍股價預測模型可解釋性不足的挑戰，  
並保持準確性，為投資決策提供更可靠的支持。

股票價格預測

信念規則模型

可解釋性

情緒分析

- 1 緒論
- 2 文獻探討
- 3 研究方法
- 4 實驗設計與結果
- 5 結論

# 1 緒論

# 1 緒論 / 1.1 研究背景

## 股票市場與其發展

全球股票市場快速發展，2013至2023年全球總市值已增長 71%，為資金募集與投資的重要平台，長期以來投資者試圖運用各種方法來預測股價走勢。

## 股價預測技術發展

股價預測技術從基本面與技術面分析，發展到透過線性、統計模型預測，再到近年引入人工智慧與大語言模型，並納入多種影響因子，預測的準確性逐漸提升。

# 1 緒論 / 1.2 研究動機

## 可解釋性 “人類能夠理解 Interpretability 決策原因的程度”

- 1 目前普遍使用的股價預測模型多為黑箱模型
- 2 黑箱模型通常缺乏可“解釋性”
- 3 模型的可解釋性對高風險的股票市場致關重要

## 信念規則模型 Belief Rule-Based Model

- 1 使用“信念結構”的基於規則的模型
- 2 模型基於規則，因此具有可解釋性
- 3 能夠靈活處理不確定和模糊性
- 4 已被應用於多個領域，並展現出良好預測能力

# 1 緒論 / 1.3 研究目的

## 1 預測股票價格

通過信念規則推理與深度學習技術的結合，預測股票價格的未來走勢。

## 2 提升解釋力

通過規則模型的邏輯推理，達到對股票價格預測過程的清晰解釋。

## 3 提升準確性

透過多因子進行預測，並使用深度學習技術優化參數，以提升預測結果的準確性。

# 2 文獻探討

## 2 文獻探討 / 2.1 股價預測模型

### 黑箱模型

通常能提供較高的預測準確率，  
但缺乏解釋能力。

SVM LSTM CNN

### 白箱模型

易於理解和解釋，但在處理複雜的非線性數據時通常準確率較低。

Linear Regression Decision Tree Rule-Based System  
Fuzzy System

### 灰箱模型

介於黑箱和白箱模型之間，在準確性與可解釋性上取得了平衡。

● 神經模糊模型 Neuro-Fuzzy ● 自適應神經模糊推理 ANFIS

● 信念規則模型 Belief Rule-Based Model with Machine Learning

## 2 文獻探討 / 2.2 基於規則的模型

### 基於規則的 模型

是人工智慧的一種早期形式，依賴於明確定義的「If-Then」規則來模擬決策過程，最早被應用於專家系統 (Expert System) 中。

### 模糊邏輯推 理模型

以模糊邏輯 (Fuzzy Logic) 和近似推理 (Approximate Reasoning) 進行改進的基於規則的模型。

### 信念規則模 型

以 RIMER 推理方法進行擴展的一種 信念結構模糊邏輯推理模型

## 2 文獻探討 / 2.3 多因子股價預測

／核心在於將多個影響股價波動的因子納入模型中，以提升預測準確性。／

1993 Fama & French 提出三因子模型，通過引入規模風險因子、淨值市價比因子和市場風險因子，改進了資本資產定價模型(CAPM)的不足，成為多因子股價預測模型的發展基礎。

Wu et al. 提出的 S\_I\_LSTM 模型，結合歷史股價、技術指標及財經新聞和社交媒體貼文，利用 LSTM 進行股價預測，在中國股市上驗證了多因子數據融合對提高預測準確率的重要性，且該模型的均方誤差 (MAE) 顯著低於其他方法。

2022

# 3 研究方法

# 3 研究方法 / 3.1 研究架構

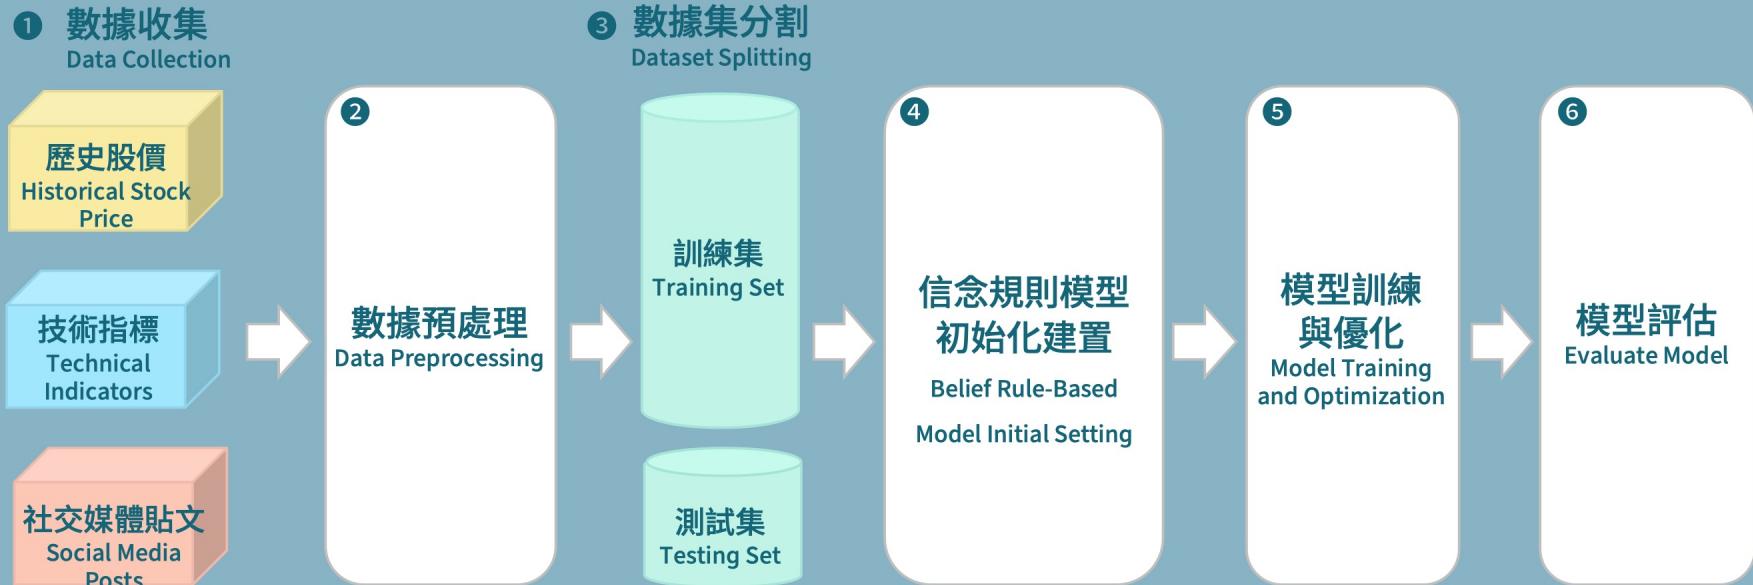


圖 1：基於信念規則的多因子深度學習模型架構圖

### 3 研究方法 / 3.2 數據來源

#### 歷史股價 Historical Stock Price

以台灣加權股價指數 (TAIEX) 及其市值佔比前三大之成分股—台積電、聯發科以及鴻海作為主要研究對象，收集2015年農曆後開盤日（2015/2/24）至2025年農曆前封盤日（2025/1/22），跨度10年的歷史股價數據。

#### 技術指標 Technical Indicators

選擇五種震盪指標作為技術指標因子，分別是指數平滑異同移動平均線 (MACD)、相對強弱指標 (RSI)、威廉指標 (%R) 和隨機指標中的 %K 值和 %D 值。

#### 社交媒體貼文 Social Media Posts

收集台灣 PTT 社交平台股票版上「心得」、「請益」、「閒聊」三種類型的貼文。

# 3 研究方法 / 3.3 模型架構

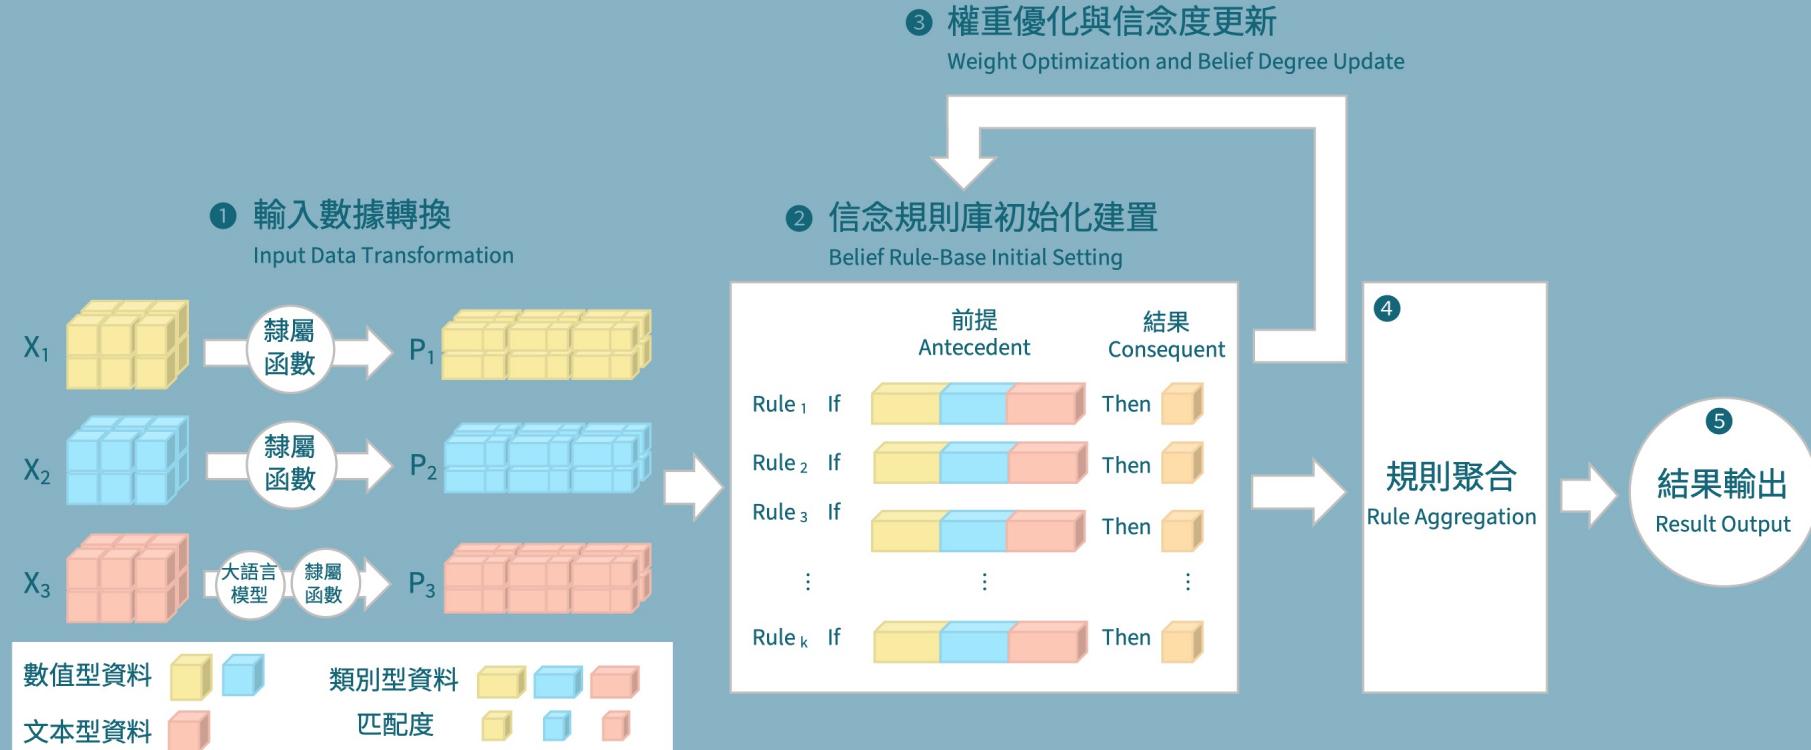


圖 2：信念規則模型架構

信念規則模型因基於明確的規則能夠提供透明且合理的解釋。

**傳統規則**  $R_k : \text{If } A_1^k \wedge A_2^k \wedge \dots \wedge A_{T_k}^k \text{ Then } C_k$

**信念規則**  $R_k : \text{If } P_1 \text{ is } A_1^k \wedge P_2 \text{ is } A_2^k \wedge \dots \wedge P_{T_k} \text{ is } A_{T_k}^k,$   
 $\text{Then } \{(C_1, \beta_{1k}), (C_2, \beta_{2k}), \dots, (C_N, \beta_{Nk})\} \left( \sum_{i=1}^N \beta_{ik} \leq 1 \right),$   
 $\text{with a rule weight } \theta_k \text{ and attribute weights } \delta_{k1}, \delta_{k2} \dots, \delta_{k_{T_k}}, \quad k \in \{1, \dots, L\}$

**前提屬性**

$P_{T_k} \text{ is } A_{T_k}^k$

**結果**

$(C_N, \beta_{Nk})$

**信念度**

$\sum_{i=1}^N \beta_{ik} \leq 1$

**權重**

$\theta_k, \delta_{k_{T_k}}$

### 3 研究方法 / 3.3 模型架構

## 證據推理

#### 1 輸入數據轉換：

確定輸入的前提屬性  $P_{T_k}$ ，與每個參考值  $A_T^k$  之間的關係。

$$P_1, P_2, \dots, P_{T_k} \rightarrow (A_2^k, \alpha_2)^{\delta_{k2}} \wedge \dots \wedge P_3 \text{ is } (A_T^k, \alpha_T)^{\delta_{k3}}$$

#### 2 規則觸發權重計算：

計算出每條規則總的前提屬性與參考值的匹配度，接者計算出每條規則的觸發權重。

$$\alpha_k = \varphi((\delta_{k1}, \alpha_1^k), (\delta_{k2}, \alpha_2^k), \dots, (\delta_{kT_k}, \alpha_{T_k}^k))$$

$$\omega_k = \frac{\theta_k \alpha_k}{\sum_{i=1}^L \theta_i \alpha_i}$$

#### 3 信念度計算與更新：

計算並更新規則中可能結果的信念度。

$$\beta_{ik} = \frac{\sum_{t=1}^{T_k} (\tau(t, k) \sum_{j=1}^{J_t} \alpha_{tj})}{\sum_{t=1}^{T_k} \tau(t, k)}$$

#### 4 規則聚合與結果輸出：

聚合觸發規則結果的信念度，綜合考慮每條規則，生成最終的預測結果。

$$\beta_j = \frac{\mu \times [\prod_{k=1}^L (\omega_k \beta_{kj} + 1 - \omega_k \sum_{j=1}^N \beta_{kj}) - \prod_{k=1}^L (1 - \omega_k \sum_{j=1}^N \beta_{kj})]}{1 - \mu \times [\prod_{k=1}^L (1 - \omega_k)]}$$

$$y_m = \sum_{n=1}^N \mu(C_n) \times \beta_n$$

# 4 實驗設計與結果

# 4 實驗設計與結果 / 4.1 實驗數據

## 歷史股價

從yahoo finance收集了2015/2/24至2025/1/22，跨度10年的台灣加權指數和台積電、聯發科、鴻海的歷史股價數據，並將當日及前五天的收盤價作為模型特徵。

## 技術指標

計算出MACD、RSI、%R、%K、%D值，並做Min-Max標準化處理。

## PTT貼文

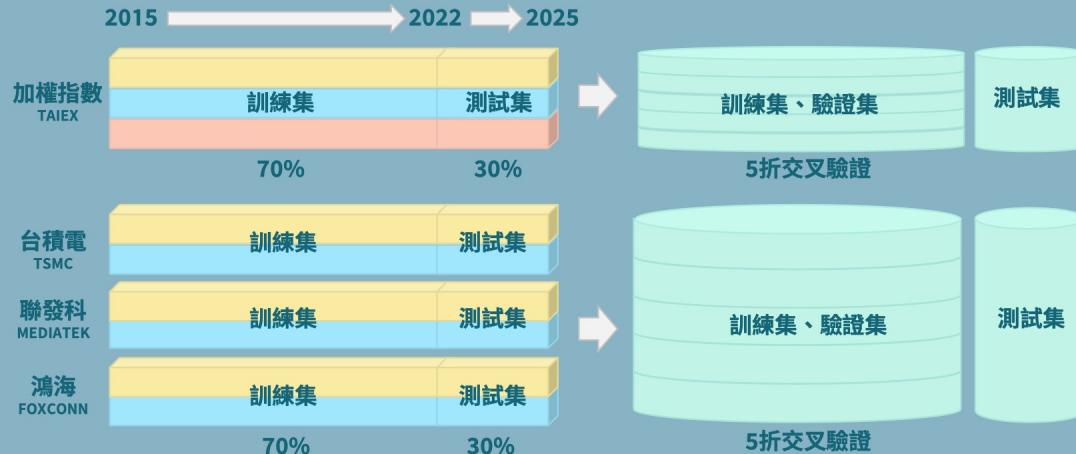
從PTT爬取2015/2/24至2025/1/22共40,354篇的貼文，並採用bert-base-multilingual-uncased-sentiment模型，將文本分為五類不同的情緒極性：強正向、弱正向、中立、弱負向和強負向，對應之量化分數為：-1.0、-0.5、0.0、0.5、1.0。

表1：輸入數據之型態與範圍

輸入數據	數據型態	數據範圍	輸入數據	數據型態	數據範圍
收盤價	Float	-1~1	MACD	Float	-1~1
前一天收盤價	Float	-1~1	RSI	Float	0~1
前兩天收盤價	Float	-1~1	K%	Float	0~1
前三天收盤價	Float	-1~1	D%	Float	0~1
前四天收盤價	Float	-1~1	R%	Float	-1~0
前五天收盤價	Float	-1~1	Sentiment	Float	-1~1

# 4 實驗設計與結果 / 4.1 實驗數據

## Dataset-taiex



## Dataset-tmf

表 2：數據集Dataset-taiex與Dataset-tmf的時間範圍

數據集	標的	訓練集	天數	測試集	天數	總天數
Dataset-taiex	加權指數	2015/2/24 ~ 2022/1/24	漲 918 跌 768	2022/1/25 ~ 2025/1/22	漲 400 跌 323	2,409
Dataset-tmf	台積電 聯發科 鴻海	2015/2/24 ~ 2022/1/24	漲 2,418 跌 2,647	2022/1/25 ~ 2025/1/22	漲 1,009 跌 1,163	7,237

## 4 實驗設計與結果 / 4.2 實驗設計

# 1 模型初始建置

## 訂定 5 類前提屬性的參考值

採用網格搜尋方法，尋找決策樹的最佳超參數組合，並使用訓練集訓練出一顆決策樹

## 以決策樹分枝節點的值，作為建構模糊邏輯中隸屬函數的依據

super low

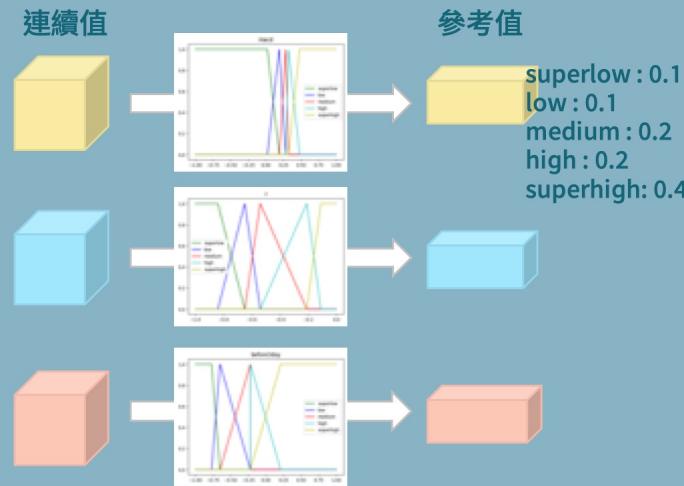
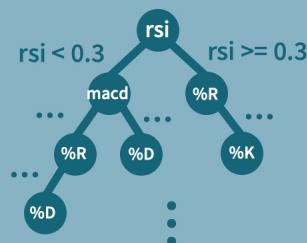
low

super high

high

medium

最大樹深為：260  
最大特徵數為：None  
分割標準為：訊息熵 (entropy)



## 4 實驗設計與結果 / 4.2 實驗設計

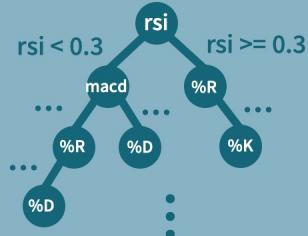
## 1 模型初始建置

# 採用網格搜尋方法，尋找決策樹的最佳超參數組合，並使用訓練集訓練出一顆決策樹

最大樹深為：260

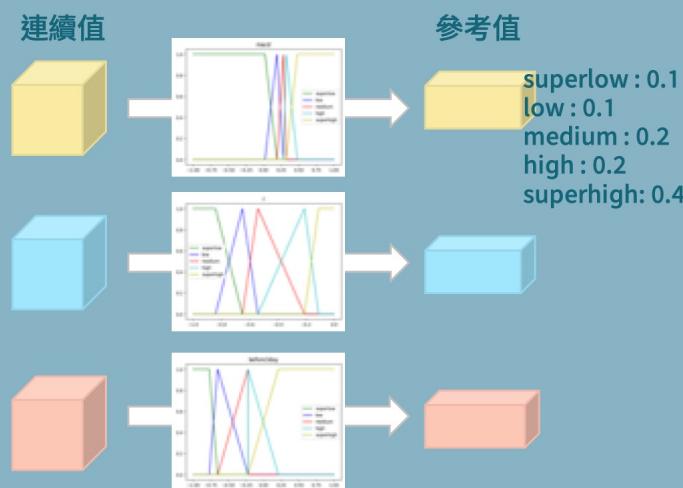
最大特徵數為：None

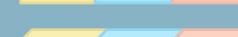
分割標準為：訊息熵 (entropy)



## 以決策樹分枝節點的值，作為建立模糊邏輯中隸屬函數的依據

使用訓練集每一筆資料生成信  
則，分別生成 1,146 和 2,364



	前提 Antecedent	結 Conse
Rule <sub>1</sub>	If 	Then
Rule <sub>2</sub>	If 	Then
Rule <sub>3</sub>	If 	Then
⋮	⋮	
Rule <sub>k</sub>	If 	Then

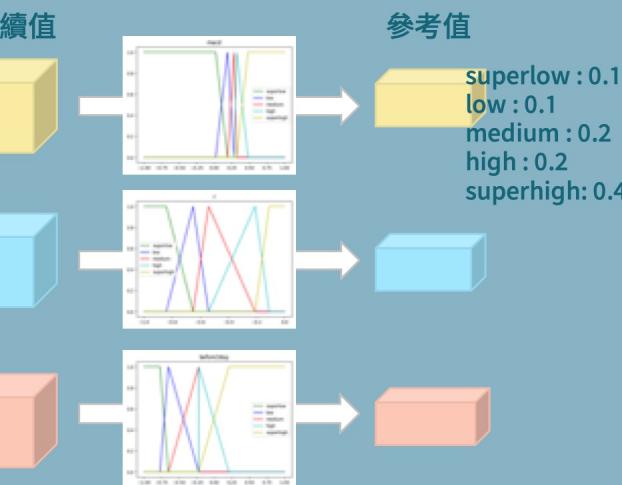
# 4 實驗設計與結果 / 4.2 實驗設計

## 1 模型初始建置

以決策樹分枝節點的值，作為建立模糊邏輯中隸屬函數的依據

使用訓練集每一筆資料生成信念規則，分別生成 1,146 和 2,364 條

初始化每條規則的參數：規則權重  $\theta$ 、前提屬性權重  $\delta$  和結果信念度  $\beta$



	前提 Antecedent	結果 Consequent
Rule <sub>1</sub>	If	Then
Rule <sub>2</sub>	If	Then
Rule <sub>3</sub>	If	Then
⋮	⋮	⋮
Rule <sub>k</sub>	If	Then

- $\theta$  規則出現的次數
- $\delta$  0~1 隨機賦值
- $\beta$  隸屬函數得出的信心值

## 4 實驗設計與結果 / 4.2 實驗設計

### 2 模型權重優化與信念度更新

使用訓練集每一筆資料生成信念規則，分別生成 1,146 和 2,364 條

初始化每條規則的參數：規則權重  $\theta$ 、前提屬性權重  $\delta$  和結果信念度  $\beta$

透過後向傳播算法找到最佳前提屬性權重  $\delta$ ，以優化模型效能

	前提 Antecedent	結果 Consequent	
Rule <sub>1</sub>	If   	Then 	
Rule <sub>2</sub>	If   	Then 	
Rule <sub>3</sub>	If   	Then 	
⋮	⋮	⋮	
Rule <sub>k</sub>	If   	Then 	

- $\theta$  規則出現的次數
- $\delta$  0~1 隨機賦值
- $\beta$  隸屬函數得出的信心值

激活函數：tanh 雙曲正切函數  
學習率：9.65E-04  
epochs : 5,000

# 4 實驗設計與結果 / 4.2 實驗設計

## 2 模型權重優化與信念度更新

初始化每條規則的參數：規則權重  
 $\theta$ 、前提屬性權重  $\delta$  和結果信念度  $\beta$

透過後向傳播算法找到最佳前提  
屬性權重  $\delta$ ，以優化模型效能

計算並更新觸發規則的信念度  $\beta$ ，  
並聚合所有觸發的規則，輸出結果

$\theta$  規則出現的次數

$\delta$  0~1 隨機賦值

$\beta$  隸屬函數得出的信心值

激活函數：tanh 雙曲正切函數

學習率：9.65E-04

epochs : 5,000

0.110 If (macd is high)  $\wedge$  (rsi is superhigh)  $\wedge$  (k is superhigh)  $\wedge$  (d is superhigh)  
 $\wedge$  (r is superhigh)  $\wedge$  (close is superlow)  $\wedge$  (before1day is high)  
 $\wedge$  (before2day is low)  $\wedge$  (before3day is superhigh)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superlow)  
Then (down,0.070) , (up,0.930)

0.005 If (macd is high)  $\wedge$  (rsi is superhigh)  $\wedge$  (k is superhigh)  $\wedge$  (d is superhigh)  
 $\wedge$  (r is superhigh)  $\wedge$  (close is superlow)  $\wedge$  (before1day is high)  
 $\wedge$  (before2day is low)  $\wedge$  (before3day is superhigh)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.083) , (up,0.917)

0.123 If (macd is low)  $\wedge$  (rsi is superlow)  $\wedge$  (k is superlow)  $\wedge$  (d is superlow)  
 $\wedge$  (r is superlow)  $\wedge$  (close is superlow)  $\wedge$  (before1day is superlow)  
 $\wedge$  (before2day is superlow)  $\wedge$  (before3day is low)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.917) , (up,0.083)

0.064 If (macd is low)  $\wedge$  (rsi is superlow)  $\wedge$  (k is superlow)  $\wedge$  (d is superlow)  
 $\wedge$  (r is superlow)  $\wedge$  (close is superlow)  $\wedge$  (before1day is superlow)  
 $\wedge$  (before2day is superlow)  $\wedge$  (before3day is low)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.083) , (up,0.917)

## 4 實驗設計與結果 / 4.2 實驗設計

### 3 模型規則聚合與結果輸出

透過後向傳播算法找到最佳前提  
屬性權重 $\delta$ ，以優化模型效能

計算並更新觸發規則的信念度 $\beta$ ，  
並聚合所有觸發的規則，輸出結果

激活函數：tanh 雙曲正切函數

學習率：9.65E-04

epoch : 5,000

0.110 If (macd is high)  $\wedge$  (rsi is superhigh)  $\wedge$  (k is superhigh)  $\wedge$  (d is superhigh)  
 $\wedge$  (r is superhigh)  $\wedge$  (close is superlow)  $\wedge$  (before1day is high)  
 $\wedge$  (before2day is low)  $\wedge$  (before3day is superhigh)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superlow)  
Then (down,0.070) , (up,0.930)

0.005 If (macd is high)  $\wedge$  (rsi is superhigh)  $\wedge$  (k is superhigh)  $\wedge$  (d is superhigh)  
 $\wedge$  (r is superhigh)  $\wedge$  (close is superlow)  $\wedge$  (before1day is high)  
 $\wedge$  (before2day is low)  $\wedge$  (before3day is superhigh)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.083) , (up,0.917)

up

0.123 If (macd is low)  $\wedge$  (rsi is superlow)  $\wedge$  (k is superlow)  $\wedge$  (d is superlow)  
 $\wedge$  (r is superlow)  $\wedge$  (close is superlow)  $\wedge$  (before1day is superlow)  
 $\wedge$  (before2day is superlow)  $\wedge$  (before3day is low)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.917) , (up,0.083)

0.064 If (macd is low)  $\wedge$  (rsi is superlow)  $\wedge$  (k is superlow)  $\wedge$  (d is superlow)  
 $\wedge$  (r is superlow)  $\wedge$  (close is superlow)  $\wedge$  (before1day is superlow)  
 $\wedge$  (before2day is superlow)  $\wedge$  (before3day is low)  $\wedge$  (before4day is superlow)  
 $\wedge$  (before5day is medium)  $\wedge$  (sentiment is superhigh)  
Then (down,0.083) , (up,0.917)

down

# 4 實驗設計與結果 / 4.3 模型評估

## 消融實驗

對比模型在多因子與單因子的情況下進行預測的表現。

## 交叉驗證

透過5折交叉驗證評估模型是存在過擬合的現象，並驗證其平均性能。

## 模型比較

與Decision Tree、LSTM和CNN近年最常被使用的白箱和黑箱模型進行比較，以評估本模型在準確性上的水平。

評估指標為準確率、精確率、召回率、F1分數

# 4 實驗設計與結果 / 4.4 實驗結果：實驗一

表 3：台灣加權指數股價預測模型評估指標比較

Model			Accuracy (%)	Precision (%)	Recall (%)	F1 (%)
BRBMDL -taiex	-w/o sentiment	cross-validation	73.61	73.40	73.48	73.40
		testing set	75.38	75.15	74.86	74.97
	-full model	cross-validation	74.67	74.54	74.47	74.42
		testing set	74.69	74.40	74.47	74.44
Decision Tree	-w/o sentiment	cross-validation	83.87	83.72	83.77	83.73
		testing set	77.59	77.42	77.69	77.47
	-full model	cross-validation	83.81	83.70	83.71	83.66
		testing set	75.90	76.25	79.34	79.13
LSTM	-w/o sentiment	cross-validation	79.18	80.08	78.79	78.71
		testing set	79.59	80.79	80.44	79.52
	-full model	cross-validation	85.47	85.62	85.00	85.17
		testing set	77.13	79.49	76.58	75.65
CNN	-w/o sentiment	cross-validation	88.73	88.82	88.92	88.65
		testing set	85.92	86.29	86.32	85.84
	-full model	cross-validation	87.92	87.87	87.77	87.79
		testing set	86.82	86.50	86.00	86.59

# 4 實驗設計與結果 / 4.4 實驗結果：實驗二

表 4：台積電、聯發科和鴻海股價預測模型評估指標比較

	Model	Accuracy (%)	Precision (%)	Recall (%)	F1 (%)
BRBMDL -tmf	cross-validation	73.68	73.92	73.91	73.68
	台積電testing set	75.69	76.12	75.87	75.66
	聯發科testing set	75.28	75.39	75.46	75.27
	鴻海testing set	77.07	76.88	77.24	76.92
Decision Tree	cross-validation	85.13	85.09	85.14	85.10
	台積電testing set	84.01	84.02	84.04	84.00
	聯發科testing set	83.04	82.97	83.02	82.99
	鴻海testing set	83.48	83.25	83.65	83.35
LSTM	cross-validation	89.22	89.26	89.15	89.18
	台積電testing set	85.39	85.71	85.46	85.36
	聯發科testing set	87.24	87.29	87.16	87.18
	鴻海testing set	87.10	86.97	87.35	87.00
CNN	cross-validation	88.04	88.42	87.93	87.95
	台積電testing set	85.08	86.27	84.85	84.86
	聯發科testing set	88.59	89.23	88.32	88.45
	鴻海testing set	86.52	86.46	86.15	86.27

# 4 實驗設計與結果 / 4.4 實驗結果：模型解釋性評估

## BRBMDL



基於信念規則架構，有清楚的「If-Then」規則，讓使用者能夠直觀的理解其中的邏輯，Hossain et al. (2022) 指出，透過各樣權重能理解不同規則、不同特徵對預測結果的貢獻和影響程度。

## Decision Tree



具備分層結構，有一定的解釋能力，但Breiman (2001)指出，Decision Tree 分支節點上的數值純粹基於數據驅動，缺乏背景知識支持，使用者難以直觀理解背後的意義。

## LSTM CNN



根據 Goodfellow et al. (2016)，深度學習模型因其複雜的層次結構與非線性轉換，內部決策過程難以解釋，且模型參數調整依賴大規模數據訓練，進一步加劇了其不透明性。

# 5 結論

## 5 結論 / 5.1 研究結論

- 1 本研究開發的 BRBMDL 針對 BRBMDL-taiex 與 BRBMDL-tmf 做訓練的版本，在整體準確率方面雖略低於其他比較模型，但仍然維持在70%以上，表示此模型在股價預測中具有一定的水準。
- 2 在 BRBMDL 建置過程中，透過使用 Decision Tree 建立隸屬函數，明確界定參考值的模糊集合，並且在模型訓練中，結合反向傳播算法，動態的優化權重，並更新信念度，使其可靈活的適應不同的數據集，且都達到良好的預測準確率。
- 3 與傳統黑箱模型相比，BRBMDL 最大的優勢在於他的解釋能力，因 BRBMDL 模型透過明確的信念規則結構，能清楚呈現輸入變數如何影響預測結果，並透過屬性權重、規則權重與信念度等參數，表明不同特徵、不同規則，對結果的相對重要程度，以簡明易懂的規則，提供使用者清晰的決策解釋。

## 5 結論 / 5.2 研究貢獻

近年來，越來越多研究指出，模型解釋能力對實務應用的重要性…

本研究引入基於信念規則 (BRB) 的模型作為預測模型，並結合深度學習技術進行優化，開發出 BRBMDL 模型，實驗以台灣加權股價指數及市值前三大成份股—台積電、聯發科和鴻海為對象進行驗證：

相較於黑箱模型 (LSTM、CNN) 和白箱模型 (Decision Tree)，BRBMDL 擁有清楚的邏輯規則，和可追溯的推理過程，不僅實現相當的預測能力，同時還具備解釋能力，在高風險的金融領域中具有實務應用潛力。

## 5 結論 / 5.3 研究限制與未來展望

- 1 未來可拓展數據來源至其他跟股票討論有關之社交媒體平台，例如Facebook、YouTube 投資頻道評論區、Dcard 財經版等，另外，可引入更細緻的情緒極性，不僅侷限於正向/負向，亦可納入其他情緒，如恐懼、貪婪、樂觀、焦慮等，以加強對情緒極性的正確捕捉。
- 2 未來研究應考慮擴大樣本涵蓋範圍，納入不同產業的股票，進行研究，以增強信念規則庫的適應性，擴大模型在金融市場上的適用範圍。
- 3 未來研究可進一步引入多種優化器（如 Adam、RMSprop 或自適應學習率調整機制）進行比較，探討其對模型收斂速度、準確率與穩定性的影響，從而提升整體預測效能與泛化能力。

# QA